

Checkpoint Especialista em IA - Nível 2



Você completou o simulado do curso

VOCÊ ACERTOU 10 DE 10

Confira suas respostas comentadas abaixo:

RESPOSTAS INVENTADAS NO CHATBOT DA VOLL

A Clínica Médica Voll, especializada em serviços médicos e exames, implementou um chatbot baseado em LLM para orientar pacientes sobre preparos de exames. Após algumas semanas, a equipe de qualidade identificou que o chatbot informou a uma pessoa paciente que o jejum para exame de glicose seria de apenas duas horas, quando o correto são oito a doze horas. A resposta soava convincente e bem estruturada, mas era factualmente incorreta. A equipe que você integra precisa classificar esse tipo de falha para definir a estratégia de correção.

Como se classifica esse tipo de falha em LLMs e por que ela é especialmente perigosa em contextos clínicos?



Trata-se de alucinação, pois o modelo gerou conteúdo plausível e coerente na forma, porém factualmente incorreto, sendo perigosa em contextos clínicos porque a aparência convincente pode levar pacientes a seguir orientações erradas sem questionar.

Correta, pois alucinação é a geração de informação falsa com aparência

confiável, o que em saúde pode causar danos reais.

CICLO DE RACIOCÍNIO NO ATENDIMENTO DA METEORA

A Meteora, loja online de roupas e acessórios, implementou um agente de atendimento baseado no padrão ReAct. Uma cliente pergunta: "Vocês têm a jaqueta jeans tamanho M em estoque?". O agente deve seguir o ciclo completo: Pensamento, Ação, Pausa e Observação antes de formular a resposta final. Porém, a equipe percebeu que o agente às vezes pula diretamente para a resposta sem consultar o sistema de estoque.

Qual etapa do ciclo ReAct está sendo ignorada e qual a consequência para a confiabilidade da resposta?



A etapa de Ação é ignorada, pois o agente não executa a consulta ao estoque, eliminando também Pausa e Observação, o que faz a resposta ser fabricada sem dados reais.

Correta, pois sem a Ação não há chamada à ferramenta, invalidando as etapas seguintes e comprometendo a confiabilidade.

EVITANDO O AGENTE MONOLÍTICO NA HERMEX LOG

A Hermex Log, empresa de logística especializada em serviços de entrega, está desenvolvendo um assistente inteligente para atender clientes. Inicialmente, a equipe criou um único agente responsável por rastreamento de encomendas, cálculo de frete, agendamento de coletas e atendimento a reclamações. Com o crescimento do projeto, o agente passou a consumir muitos tokens, ficou difícil de manter e qualquer alteração em um domínio impactava os demais. A equipe que você integra precisa justificar a migração para uma arquitetura multi-agente. Considere que cada domínio possui regras de negócio extensas e fluxos conversacionais longos, e que a volumetria de solicitações de rastreamento é muito superior à de reclamações.

Qual é o principal argumento técnico para migrar de um agente monolítico para múltiplos agentes especializados?



Separar em agentes especializados isola domínios com regras e volumetrias distintas, reduzindo o consumo de tokens por contexto enxuto, evitando que mudanças em um domínio quebrem outros e permitindo escalar cada agente de forma independente conforme a demanda.

Correta, pois aborda isolamento de domínios, economia de tokens e escalabilidade independente como benefícios centrais da arquitetura multi-agent.

DESCOBERTA DE FERRAMENTAS NA JORNADA MILHAS

A Jornada Milhas, plataforma para compras de passagens aéreas utilizando milhas, precisa conectar um agente de IA ao sistema de reservas, que já possui uma API REST. O agente deve descobrir sozinho quais operações estão disponíveis — buscar voos, reservar passagens, consultar saldo de milhas — sem depender de documentação externa. Porém, a API REST atual não oferece nenhuma rota padronizada que liste suas próprias capacidades. A equipe de backend argumenta que o REST já é padronizado porque usa métodos HTTP (GET, POST, PUT, DELETE) e isso seria suficiente para o agente operar de forma autônoma.

Por que a padronização dos métodos HTTP não resolve o problema de descoberta automática de capacidades pelo agente?



Porque métodos HTTP padronizam o tipo de operação, mas não informam quais rotas existem, o que cada endpoint faz ou quais parâmetros aceita, impedindo a descoberta autônoma.

Correta, pois sem rota de descoberta e descrição padronizada, o agente

não consegue identificar autonomamente as capacidades disponíveis.

ESPECIALIZAÇÃO DO CHATBOT DA ADOPET

A ADOPET, um site de adoção de animais de estimação, recebe centenas de perguntas diárias sobre requisitos de adoção, vacinas obrigatórias e taxas por espécie. A empresa contratou você para decidir entre duas abordagens de especialização do LLM: fine-tuning ou RAG. As regras de adoção mudam frequentemente conforme legislação municipal, e a ADOPET não dispõe de orçamento para infraestrutura de GPU dedicada. Novos abrigos parceiros são cadastrados semanalmente, cada um com políticas próprias, e a equipe precisa que o sistema reflita essas atualizações rapidamente, sem necessidade de retreinar o modelo a cada mudança.

Qual abordagem de especialização do LLM é mais adequada considerando custos, frequência de atualização e infraestrutura disponível?



Adotar RAG, conectando o LLM a uma base vetorial de documentos atualizáveis, permitindo que mudanças nas regras de adoção e novos abrigos sejam refletidos imediatamente sem retreinamento e sem custos de GPU dedicada.

Correta, pois RAG consulta bases externas atualizáveis em tempo real, eliminando retreinamento e custos de GPU.

FERRAMENTAS AUSENTES NO FESTIVAL CODECHELLA

A CodeChella, organização de um festival de música com diversas atrações, criou um agente ReAct para responder dúvidas do público. O agente possui duas ferramentas: `consultar_programacao` (retorna horários de shows por palco) e `consultar_ingressos` (retorna disponibilidade por tipo de ingresso). Uma pessoa participante pergunta: "Qual é a atração mais popular do festival?". O agente raciocina corretamente e identifica que precisaria comparar dados de vendas ou audiência de todas as atrações, mas não possui uma ferramenta que forneça esse ranking.

O que o agente ReAct deve fazer quando identifica que nenhuma das ferramentas disponíveis é capaz de responder à pergunta formulada?



Reconhecer suas limitações e informar à pessoa participante que não consegue determinar a atração mais popular, pois não possui ferramenta de ranking ou comparação de audiência disponível.

Correta, pois o agente ReAct deve comunicar transparentemente sua incapacidade quando nenhuma ferramenta cobre a consulta.

REGISTRANDO NOVA AÇÃO NO PROMPT DA CHECKLIST

A Checklist é uma plataforma de gestão de tarefas e checklists para equipes. A equipe de desenvolvimento criou um agente ReAct com duas ferramentas: `consultar_tarefas_pendentes` e `consultar_responsavel`. Agora, implementaram uma terceira função chamada `calcular_carga_trabalho_equipe`, que soma as tarefas de todas as pessoas membras. A função foi codificada corretamente e adicionada ao bloco de despacho condicional (`elif`) do agente. Porém, ao testar com a pergunta "Qual a carga total de trabalho da equipe de design?", o agente não reconhece a nova ação e tenta responder sem consultá-la. A equipe revisou o código da função e do `elif`, e ambos estão corretos.

Qual etapa foi esquecida pela equipe, tornando a nova ferramenta invisível ao agente?



A equipe esqueceu de registrar a nova ferramenta no prompt do agente, incluindo sua descrição e um exemplo de uso, impedindo que o modelo saiba que essa ação existe e possa selecioná-la.

Correta, pois sem o registro no prompt o modelo desconhece a ação e

nunca a escolhe, mesmo com o despacho implementado.

ROTEANDO PEDIDOS NO GATITO PETSHOP

O Gatito Petshop é uma loja que oferece produtos e serviços para animais de estimação. A empresa contratou você para projetar um assistente multi-agent com três agentes especializados: agendamento de banho e tosa, vendas de produtos e atendimento veterinário. A equipe optou pelo padrão de roteamento com uma pessoa supervisora que classifica a intenção da pessoa cliente e direciona ao agente correto. Uma pessoa cliente envia a mensagem "quero agendar um banho para meu gato e também comprar uma ração premium".

Qual é a diferença prática entre usar o padrão router e o padrão de subagentes para atender essa solicitação com duas intenções simultâneas?



No padrão router, a pessoa supervisora aciona ambos os agentes e um sintetizador combina as respostas em uma única resposta coesa; no padrão de subagentes, cada agente opera com contexto isolado, sem síntese automática.

Correta, pois o router permite acionamento paralelo com síntese, enquanto subagentes mantêm contextos isolados sem combinação.

ESTRATÉGIA COMBINADA CONTRA ALUCINAÇÕES NA BUSCANTE

A Buscante, buscador e e-commerce de livros variados, utiliza um LLM para gerar resenhas automáticas e recomendar títulos. Recentemente, o modelo inventou autores inexistentes e atribuiu obras a escritores errados. A equipe propôs três ações: curar a base de dados com normalização de nomes, implementar um verificador automático que cruza informações geradas com o catálogo real e realizar fine-tuning com dados específicos do acervo. Uma pessoa da equipe argumentou que bastaria aplicar apenas o fine-tuning.

Por que confiar exclusivamente no fine-tuning seria insuficiente para resolver o problema de alucinações?



Porque cada técnica ataca uma dimensão diferente: dados curados reduzem a fonte de erro, verificadores capturam falhas em tempo real e fine-tuning especializa o modelo, sendo necessário combiná-las para cobrir todas as vulnerabilidades.

Correta, pois aplicar apenas uma técnica deixa as demais dimensões do problema expostas a alucinações.

FRAGMENTAÇÃO DE POLÍTICAS NA ORGANO

A Organo, uma plataforma de criação e gestão de organogramas empresariais, está construindo um sistema RAG para responder perguntas sobre políticas internas de clientes corporativos. O documento de política de promoções de um cliente possui parágrafos longos e densos, com critérios interligados ao longo de várias linhas. A equipe que você integra optou por chunking de tamanho fixo com 30 caracteres por chunk, sem sobreposição. Nos testes, o retriever retornou chunks com frases cortadas ao meio, como "o colaborador deve ter no míni" e "mo 2 anos de empresa para", tornando as respostas do LLM incoerentes.

Que ajustes resolveriam o problema de chunks incompletos nesse cenário?



Aumentar o tamanho dos chunks, adotar estratégia de chunking por parágrafos para preservar a coesão do texto denso e aplicar overlapping entre chunks consecutivos, garantindo continuidade de contexto nas fronteiras.

Correta, pois combina chunks maiores, segmentação semântica por parágrafos e sobreposição para evitar cortes que destroem o significado.

